

Reporte de Modelos

Proyecto Integrador FinanceGuard

Reducción de Churn en Banca Digital

Documento Técnico Final, Avance 4

Simón Bedoya

Soy Henry, Carrera de Data Science

Dirigido al Equipo de Retención de FinanceGuard

1. Resumen Ejecutivo

FinanceGuard enfrenta una tasa de abandono de clientes del 20,4 por ciento anual, lo que representa pérdidas significativas y una amenaza directa para el crecimiento del banco. A lo largo de tres avances desarrollé modelos supervisados, con Regresión Logística y Gradient Boosting, y análisis no supervisado, con clustering y reducción de dimensionalidad, para entender y predecir el abandono.

Este reporte consolida los resultados de cada avance, compara el rendimiento de los modelos, sintetiza los aprendizajes y presenta recomendaciones estratégicas para el equipo de retención. La meta del proyecto es apoyar la reducción del churn del 20 al 15 por ciento.

Hallazgos principales

- **Mejor modelo supervisado:** El XGBoost optimizado y el ensamble de Stacking empataron como los mejores, ambos con ROC-AUC de 0,870 y recall de 0,76, detectando el 76 por ciento de los clientes que se van.
- **Ganancia frente al baseline:** Los modelos de Gradient Boosting superaron a la Regresión Logística en discriminación, elevando el ROC-AUC de 0,777 a 0,870, gracias a su capacidad de capturar relaciones no lineales.
- **Segmentación de clientes:** K-Means con K igual a 3 identificó un segmento de alto riesgo, los clientes de Alemania, con 32,4 por ciento de churn, frente a cerca del 16 por ciento en los otros segmentos.
- **Variables clave:** La edad, el número de productos, el saldo y la condición de miembro activo son los predictores más importantes, tanto en los modelos supervisados como en los perfiles de segmento.

Nota sobre la arquitectura del proyecto: los tres avances están encadenados. El Avance 1 exporta el conjunto de datos ya limpio y codificado, y los avances 2 y 3 lo consumen como punto de partida. El escalado se realiza dentro de cada avance, después de dividir en entrenamiento y prueba, para evitar la fuga de datos. Este diseño garantiza consistencia en el preprocesamiento y hace que la comparación entre modelos sea limpia.

Tabla resumen del proyecto

Avance	Técnica principal	Resultado clave
Avance 1	Regresión Logística	Baseline: ROC-AUC 0,777, recall 0,70
Avance 2	XGBoost optimizado	Mejor modelo: ROC-AUC 0,870, recall 0,76
Avance 3	K-Means (K=3)	Segmento Alemania: 32,4% de churn

2. Síntesis por Avance

2.1 Avance 1, Regresión Logística

Objetivo: establecer un modelo base interpretable para predecir el churn, que sirva de referencia para los modelos más complejos.

Métrica	Valor	Interpretación
Accuracy	0,71	Correcto en 7 de cada 10 predicciones
ROC-AUC	0,777	Buena capacidad de discriminación

Métrica	Valor	Interpretación
Precision	0,39	De los alertados como churn, el 39% se va
Recall	0,70	Detecta el 70% de los clientes que se van
F1-Score	0,50	Balance entre precisión y recall

El modelo se entrenó con manejo del desbalance mediante ponderación de clases, lo que explica el recall alto: la prioridad fue detectar a la mayor cantidad posible de clientes en riesgo, aun a costa de generar algunas falsas alarmas.

Coeficientes más importantes

- **Edad, efecto positivo.** A mayor edad, mayor probabilidad de churn, con un odds ratio de 2,23.
- **Alemania, efecto positivo.** Los clientes de Alemania tienen más del doble de riesgo que los de Francia, con odds ratio de 2,28.
- **Saldo, efecto positivo.** Un saldo alto se asocia a mayor churn, un patrón contraintuitivo que sugiere clientes que preparan su salida.
- **Miembro activo, efecto negativo.** Los miembros activos abandonan mucho menos, con odds ratio de 0,41, el principal factor protector.
- **Número de productos.** Efecto no lineal que el modelo lineal captura mal: con 2 productos el churn es mínimo, pero con 3 o 4 se dispara.

Fortalezas y limitaciones

- **Fortalezas.** Fácil de explicar al negocio mediante coeficientes y odds ratios, rápido de entrenar y desplegar, entrega probabilidades para priorizar acciones, y sirve como referencia sólida.
- **Limitaciones.** Modela relaciones lineales, por lo que subestima interacciones y no captura bien los patrones no lineales que sí aprovechan los árboles, como el efecto del número de productos.

2.2 Avance 2, Gradient Boosting y Optimización

Objetivo: mejorar la predicción del churn con modelos de ensamble y optimización de hiperparámetros, superando el baseline.

Se entrenaron cuatro modelos de árboles (Random Forest, XGBoost, LightGBM y CatBoost), se optimizó el XGBoost con Grid Search, y se construyó un ensamble de Stacking con los tres modelos de boosting y un metamodelo logístico. El mejor desempeño lo alcanzaron, empatados, el XGBoost optimizado y el Stacking.

Modelo	ROC-AUC	Recall
Random Forest	0,864	0,68
XGBoost (base)	0,866	0,74
LightGBM	0,856	0,71
CatBoost	0,866	0,74
XGBoost (optimizado)	0,870	0,76

Modelo	ROC-AUC	Recall
Stacking (3 modelos)	0,870	0,76

Los parámetros óptimos del XGBoost, hallados con Grid Search sobre 16 combinaciones, fueron profundidad máxima 3, tasa de aprendizaje 0,1, cien árboles y submuestreo 0,8. Es notable que la profundidad óptima sea baja, lo que indica que árboles simples generalizan mejor en este problema.

Importancia de variables del mejor modelo

El orden de importancia según el modelo fue: número de productos, edad, saldo, condición de miembro activo, y país. Este resultado confirma un hallazgo clave del Avance 1: los modelos de árboles sí aprovechan el efecto no lineal del número de productos, que la regresión logística desperdiciaba, lo que explica en parte su mejor desempeño.

Ganancia frente al baseline

Métrica	Avance 1	Avance 2	Mejora
ROC-AUC	0,777	0,870	Discriminación superior
Recall	0,70	0,76	Más churners detectados
F1-Score	0,50	0,61	Mejor balance global

El boosting captura interacciones y no linealidades que la regresión logística no modela de forma explícita. La validación cruzada estratificada de cinco pliegues, con métrica ROC-AUC, aseguró una evaluación estable pese al desbalance de clases. Una reflexión relevante: el Stacking,

mucho más complejo, no superó al XGBoost optimizado, lo que confirma que la complejidad no garantiza mejores resultados.

2.3 Avance 3, Aprendizaje No Supervisado

Objetivo: segmentar a los clientes sin usar la etiqueta de churn, para descubrir perfiles y cruzarlos después con la tasa de abandono.

Segmento	Cientes	Saldo medio	Churn
Segmento Alemania	2.509	119.730 USD	32,4%
Segmento Francia	5.014	62.093 USD	16,2%
Segmento España	2.477	61.818 USD	16,7%

K-Means con K igual a 3, elegido por el método del codo y el coeficiente de silueta, dividió a los clientes en tres segmentos que resultaron corresponder a los tres países. Cabe notar que el número que K-Means asigna a cada segmento es arbitrario y puede variar entre ejecuciones, así que los identifiqué por su país, no por su número. El hallazgo más valioso es que el clustering, sin usar la variable de churn, identificó por su cuenta el mismo segmento de alto riesgo, Alemania, que los modelos supervisados ya habían señalado.

Insights de negocio por segmento

- **Segmento Alemania.** Prioridad máxima de retención. Concentra el mayor riesgo (32,4%) y el saldo más alto, así que son clientes valiosos y en peligro. Amerita ofertas de retención dirigidas, revisión de la experiencia en ese mercado y posible ajuste de producto o precio.

- **Segmentos Francia y España.** Churn por debajo de la media. Son el núcleo estable del banco, útiles para estrategias de crecimiento y venta cruzada sin descuidar la retención básica.
- **Sobre DBSCAN.** Generó muchos outliers por la homogeneidad de los datos, así que K-Means resultó más útil para una segmentación accionable. DBSCAN aporta valor para detectar clientes atípicos.

Features derivadas del clustering

Un aporte práctico de la segmentación es que sus resultados se convierten en nuevas variables reutilizables. Derivé dos. La primera es la etiqueta de segmento de cada cliente, que puede sumarse como variable a un modelo supervisado. La segunda es un ranking de riesgo del segmento, ordenado por su tasa de churn, donde el valor 0 corresponde al segmento de mayor riesgo. Este ranking tiene una ventaja de diseño: al basarse en el churn y no en el número arbitrario del cluster, es estable entre ejecuciones y sirve directamente para priorizar. Incluir estas variables en el modelo supervisado, o en reglas de negocio, permite aplicar umbrales más agresivos al segmento de mayor riesgo.

Consideraciones del análisis

- La segmentación no sustituye al modelo de churn, lo complementa: aporta perfiles de grupo frente a la probabilidad individual.
- El coeficiente de silueta fue bajo, cerca de 0,13, lo que indica clusters con solapamiento, algo esperable en datos de clientes reales. Aun así, las diferencias de churn entre segmentos son claras y accionables.

- El PCA reveló que las variables están poco correlacionadas, ya que la varianza se reparte entre muchos componentes, un hallazgo útil para futuros análisis.

3. Lecciones Aprendidas

3.1 Cuándo usar modelos supervisados frente a no supervisados

Criterio	Supervisado	No supervisado
Objetivo	Predecir quién y con qué probabilidad	Entender grupos y perfiles
Uso de la etiqueta	Sí, usa Exited	No, solo para análisis posterior
Salida principal	Probabilidad de churn por cliente	Segmentos y perfiles
Acción típica	Alertas y campañas por riesgo	Estrategias por segmento
Interpretabilidad	Coeficientes o importancia	Centroides y tasas por cluster

La recomendación es usar el enfoque supervisado para el scoring y la priorización diaria, por ejemplo una lista de clientes con probabilidad de churn superior al umbral, y el enfoque no supervisado para el diseño de estrategias por segmento, como un producto o un mensaje diferenciado por país. Los dos enfoques se complementan: uno dice a quién contactar, el otro cómo agrupar las acciones.

3.2 Consideraciones para futuros proyectos de churn

- **Desbalance.** Mantener métricas como ROC-AUC, recall y F1, sin depender del accuracy, que engaña con clases desbalanceadas. Usar ponderación de clases cuando se requiera priorizar la detección.

- **Umbral de decisión.** El umbral de 0,5 no es fijo. Conviene ajustarlo según el costo real de un falso negativo, perder un cliente sin detectarlo, frente al de un falso positivo, una alarma innecesaria.
- **Estabilidad.** Usar validación cruzada estratificada y, de ser posible, validación temporal, para evitar el sobreajuste y el deterioro del modelo con el tiempo.
- **Interpretabilidad.** En entornos con equipos de negocio, combinar modelos interpretables con modelos de mejor rendimiento, apoyándose en reportes de importancia y perfiles.
- **Integración con clustering.** Incluir el segmento o su nivel de riesgo como variable en el modelo supervisado, o en reglas de negocio, puede afinar la segmentación de acciones, como un umbral más agresivo en el segmento de Alemania.

4. Recomendaciones Estratégicas

1. Desplegar el mejor modelo supervisado, el XGBoost optimizado, para el scoring semanal o diario de clientes, con una lista priorizada por probabilidad de churn. Se recomienda el XGBoost sobre el Stacking por ofrecer el mismo desempeño con mucha menor complejidad.
2. Ajustar el umbral de clasificación según los costos reales de un falso negativo frente a un falso positivo, para calibrar el equilibrio entre detección y falsas alarmas.
3. Priorizar el segmento de Alemania, con acciones específicas de retención, investigación cualitativa de las causas de su alto churn, y posible ajuste de producto o canal en ese mercado.
4. Actuar sobre las variables accionables: fomentar la contratación de 2 productos, que es el punto óptimo, impulsar el engagement para aumentar los miembros activos, y vigilar a los clientes con saldo alto y edad avanzada.

5. Monitorear en producción el ROC-AUC, el F1 y la distribución de los scores, con alertas si la distribución del churn o de las variables cambia con el tiempo.
6. Cerrar el ciclo usando los resultados de las campañas de retención para reentrenar los modelos y recalibrar los umbrales de forma periódica.

5. Cierre del Proyecto

El proyecto entregó a FinanceGuard un conjunto completo de herramientas para entender y combatir el churn. Los modelos supervisados permiten predecir el abandono a nivel de cada cliente, con el XGBoost optimizado alcanzando un ROC-AUC de 0,870 y detectando el 76 por ciento de los clientes en riesgo. El análisis no supervisado aporta una segmentación accionable que identifica al mercado alemán como la prioridad de retención. La combinación de ambos enfoques, la predicción individual y la visión por segmentos, le da al banco una base sólida para diseñar estrategias dirigidas y avanzar hacia su meta de reducir el churn del 20 al 15 por ciento.